

Overfitting och underfitting i deep learning

Målet: fungera på ny data


- Träning $\neq$ verklighet
- Målet är generalisering
- Bra modell = bra på data den inte tränat på

Underfitting, lagom, overfitting

- Underfitting: modellen lär sig för lite
- Bra balans: modellen lär sig generaliserbara mönster
- Overfitting: modellen lär sig för mycket av träningsdatan


Underfitting: modellen är för svag

- Hög train loss
- Hög validation loss
- Modellen missar grundmönstret



Overfitting: modellen memorerar

- Låg train loss
- Högre validation loss
- Stort gap mellan train och validation



Varför är deep learning känsligt?

- Många parametrar
- Flexibla modeller
- Kan lära sig brus
- Kräver mycket data



Modellkapacitet


Hur mycket kan modellen lära sig?

- För låg kapacitet → underfitting
- För hög kapacitet → risk för overfitting
- Lagom kapacitet → bättre generalisering


Läs kurvorna som en diagnos



Båda dåliga:
underfitting




Train bra, validation sämre:
overfitting



Båda förbättras:
bra träning

Generalization gap

- Skillnaden mellan train och validation
- Litet gap är ofta bättre
- Stort gap = varningssignal



Vanliga orsaker

Underfitting kan bero på:

- För enkel modell
- För få epoker
- Fel learning rate
- Dålig datarepresentation

Overfitting kan bero på:

- För komplex modell
- För många epoker
- För lite data
- För lite regularisering

Bättre train-resultat är inte alltid bättre modell

- Hög train accuracy kan vara falsk trygghet
- Validation visar generalisering
- Test används först i slutet

Hur kan vi minska overfitting?

- Early stopping
- Dropout
- Regularisering
- Mer/bättre data
- Enklare modell

Overfitting och underfitting i deep learning

Joakim Lindh