


Transfer learning

Transfer learning

Idé och intuition

Att återanvända tidigare inläring i stället för att börja från noll.



Problemet: att börja från noll är dyrt

Stora modeller behöver ofta mer än bara en bra idé.

Vad en djup modell ofta behöver

mycket och varierad data
labels av rimlig kvalitet
tillräcklig beräkningskraft
tid för experiment och felsökning


Vad vi ofta har i praktiken

begränsat eget dataset
labels som är dyra eller brusiga
begränsad tid och budget
risk för överanpassning

Transfer learning minskar startkostnaden.

Grundidén

Återanvänd representationer – inte nödvändigtvis färdiga svar.



Poängen: vi flyttar över användbara representationer och tränar bara det som behövs för den nya uppgiften.

Vad är det som överförs?

Modellen återanvänder intern representation, inte bara etiketter.

Rådata

Bilder, text, ljud eller annan komplex input.



Representation

Interna features som modellen har lärt sig från tidigare träning.




Ny output

Ett nytt huvud kopplar representationen till våra egna klasser eller mål.

Basmodell och nytt huvud

En praktisk transfer learning-modell består ofta av två delar.



Steg 1: frys basmodellen

Börja ofta med att bara träna det nya huvudet.

Fryst basmodell



Vikterna ändras inte under träningen.

Ger stabil start och snabbare träning.

Nytt huvud




Vikterna tränas för den nya uppgiften.

Lär sig koppla representationer till rätt output.

Steg 2: fine-tuning

När huvudet fungerar kan vissa lager anpassas försiktigt.



Fine-tuning är inte “träna allt igen” – det är en kontrollerad anpassning.

När passar transfer learning?

Det är mest användbart när tidigare inlärning liknar det nya problemet.

Begränsad egen data

När det är svårt att träna en stor modell från grunden.

Komplex rådata

När inputen innehåller mönster som är svåra att skapa features för manuellt.

Liknande domän

När den förtränade modellen har sett data som åtminstone liknar din.

Snabbare experiment

När du vill få en stark startpunkt utan lång förträning.

Exempel finns i bild, text, ljud och många andra domäner – principen är densamma.

När ska man vara försiktig?

Transfer learning är kraftfullt, men det är inte magi.

Domängap

Den nya datan skiljer sig mycket från den data modellen tränades på.

Datakvalitet

Felaktiga, otydliga eller skeva labels blir fortfarande ett problem.

Fel komplexitet

En stor förtränad modell kan vara onödigt tung om en enklare modell räcker.

Bra transfer learning kräver fortfarande validering, felanalys och rimliga jämförelser.

Ett praktiskt arbetsflöde

Börja enkelt, återanvänd klokt, finjustera först när det behövs.



Vad behöver dokumenteras?

En bra modell är inte bara tränad – den är motiverad.

Data

Hur liknar din data den data modellen tränades på?

Val

Varför valde du transfer learning i stället för enklare alternativ?

Träning

Vad frystes, vad tränades och varför?

Resultat

Vilka fel återstår och hur allvarliga är de?

Transfer learning

Sammanfattning

återanvänder förtränade representationer
basmodell fungerar ofta som feature extractor
nytt huvud tränas för den egna uppgiften
frysta lager ändras inte under träning

fine-tuning anpassar modellen försiktigt
fungerar bäst när domänerna liknar varandra
kräver fortfarande felanalys och validering
nästa steg: implementera i Keras

Transfer learning

Joakim Lindh