


Andra arkitekturer
och vägar vidare

Översikt: andra arkitekturer och vägar vidare

Vad finns bortom Dense-nätverk, CNN och transfer learning?



En karta över vad som finns kvar att utforska – inte ett nytt stort kodkapitel.

Vad vi har byggt hittills

Fyra byggstenar vi redan har arbetat med.

1 Densit-nätverk

Grundmodell för tabulär
eller enklare data

2 CNN

Bilddata, lokala mönster
och spatial struktur

3 Transfer learning

Återanvänder förtränade
representationer


4 Enkel app

Använder modellen utanför
notebooken

Från modellträning till analys, förbättring och enkel användning.

Deep learning är inte en enda modelltyp

Olika datatyper och uppgifter leder till olika arkitekturer.



Arkitekturen väljs utifrån problem, data och mål – inte tvärtom.

Sekvensmodeller

När ordning och sammanhang över tid spelar roll.



Exempel på sekvensdata

text
tidsserier
ljud
sensordata
loggar

RNN, LSTM och GRU läser sekvensen steg för steg och behåller intern information.

Historiskt viktiga – men transformers dominerar många moderna sekvensproblem.

Transformers och attention

Att väga relationer mellan delar av inputen.



Attention

Modellen väger relationer mellan delar av inputen.

Text, kod, bild, ljud och multimodala system

En central arkitektur i modern deep learning, men inte automatiskt rätt för alla problem.

Autoencoders

Representationen, rekonstruktion och avvikelstdetektion.



Används för komprimering, brusreducering, representationer och anomaly detection.

Generativa modeller

Modeller som skapar ny data.

GANs

Generator
försöker skapa realistisk data → Discriminator
försöker skilja riktig från genererad data


Diffusion

Brus → stegvis denoising → Ny data

Klassificeringsmodeller väljer mellan klasser. Generativa modeller skapar nytt innehåll.

Multimodala modeller

Flera datatyper i samma system.



Exempel: fråga om en bild, skapa bild från text, kombinera video och språk.

Modellen är bara en del av lösningen

Praktisk användning kräver mer än bra accuracy.



Risker

ny miljö
dataset shift
fel med konsekvens

Dokumentation

syfte
data
begränsningar

Ansvar

rätt förväntningar
mänsklig granskning
uppföljning

Vägar vidare

Välj nästa steg utifrån vilken typ av problem du vill lösa.

Bilder

CNN, transfer learning, vision transformers

Text

NLP, tokens, embeddings, transformers

Tidsdata

sekvensmodeller och transformers

Generera data

GANs, diffusion och generativa metoder

Representationer

autoencoders och anomaly detection

Bygga appar

API:er, Gradio, Streamlit och deployment

Försök inte lära allt samtidigt. Välj riktning utifrån data och problem.

En arbetsprocess att ta med sig

Ett systematiskt sätt att arbeta med modeller.

1 Förstå problemet

2 Titta på datan

3 Börja enkelt

4 Träna modell

5 Följ validation

6 Analysera fel

7 Förbättra stegvis

8 Dokumentera

9 Använd rimligt

Kod och bibliotek förändras. En bra arbetsprocess håller längre.

Avslutning

Bygg inte bara modeller – förstå dem.

Det vi tar med oss

Deep learning är kraftfullt, men kräver eftertanke.

Rätt arkitektur beror på data och problem.

Bra modeller byggs stegvis och analyseras.

Sista poängen

Förstå problemet.

Förstå datan.

Välj modell med motivering.

Analysera felen.

Dokumentera begränsningar.

Använd modellen ansvarsfullt.

Bygg inte bara modeller – förstå dem.